



Python

机器学习实战

线性回归和梯度下降

线性回归

预测

连续型变量

回归（线性回归，广义线性回归、CART）


离散型变量

分类（逻辑回归、SVM、决策树…）



广告费和销量

- 销量随着广告费的投入增加而增加吗？
- 能不能定量的描述广告投入和销量之间的关系？
- 广告费对于销量的影响有统计意义吗？
- 贡献有多大？
- 能不能根据广告投入预测销量？
-



线性回归


不独立两个随机变量，二者之间肯定会有某种关系：

确定性关系


- 函数关系

非确定关系

- 线性关系（相关关系）
- 非线性关系



函数关系



线性（正）相关

线性回归


散点图观察相关性

相关性的程度

- 相关系数

相关关系不是因果关系

独立和不相关



协方差

- COV
- 协方差取值范围 $(-\infty, +\infty)$

$$\begin{aligned}Cov(X, Y) &= E[(X - E[X])(Y - E[Y])] \\&= E[XY] - 2E[Y]E[X] + E[X]E[Y] \\&= E[XY] - E[X]E[Y]\end{aligned}$$

相关系数

- cor
- 对协方差的单位化，取值范围 $[-1, +1]$

$$\rho_{XY} = \frac{Cov(X, Y)}{\sqrt{D(X)}\sqrt{D(Y)}}$$


最小二乘法

线性回归

一元线性回归

$$Y = \beta_0 + \beta_1 X_1 + \varepsilon$$


- ε 代表残差（误差）



线性回归

多元线性回归

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_m X_m + \varepsilon$$




线性回归

最佳回归线

不同的人会找到不同的“最佳”回归线

残差平方和最小为“最佳”



最小二乘法 (OLS)

- 残差平方和最小
- 残差就是y的实际值和y的回归值之间的差异，就是随机误差

目标函数

$$J(\theta) = \frac{1}{2} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

梯度下降法

数值优化


- 解析解
- 数值解
- 在机器学习中，基本上都是求数值解，只有线性回归能得到解析解

为什么要用梯度下降方法求解

- 绕过对于矩阵求逆
- 在计算机算法上会更容易实现

高等数学知识复习

- 微分
- 全微分和偏微分
- 梯度向量
- 方向导数
- **梯度方向是函数值变化最快的方向**
- 梯度方向指向函数值增大的方向，负梯度方向指向函数值减少的方向



梯度的推导

$$\begin{aligned}\frac{\partial}{\partial \theta_j} J(\theta) &= \frac{\partial}{\partial \theta_j} \frac{1}{2} (h_{\theta}(x) - y)^2 \\ &= 2 \cdot \frac{1}{2} (h_{\theta}(x) - y) \cdot \frac{\partial}{\partial \theta_j} (h_{\theta}(x) - y) \\ &= (h_{\theta}(x) - y) \cdot \frac{\partial}{\partial \theta_j} \left(\sum_{i=0}^n \theta_i x_i - y \right) \\ &= (h_{\theta}(x) - y) x_j\end{aligned}$$

梯度下降法伪代码


```
Repeat until convergence {  
     $\theta_j := \theta_j + \alpha \sum_{i=1}^m (y^{(i)} - h_{\theta}(x^{(i)})) x_j^{(i)}$   
}
```

α 学习速率，超参数

线性回归

决定系数 R^2

- 贡献有多大?
- 回归平方和占总平方和的比例
- 等于相关系数的平方



岭回归

线性代数无法求解

- 变量之间存在线性关系
- 变量数量大于记录数

不存在广义逆

$$Y = X\beta + \varepsilon$$

$$\beta = (X^T X)^{-1} X^T y$$

引入扰动后求解

等价于


$$\hat{\boldsymbol{\beta}}(k) = (\mathbf{X}^\top \mathbf{X} + k\mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y}$$

$$\hat{\beta}^{\text{ridge}} = \underset{\beta}{\operatorname{argmin}} \left\{ \sum_{i=1}^N \left(y_i - \sum_{j=1}^p x_{ij} \beta_j \right)^2 + \textcolor{red}{k} \sum_{j=1}^p \beta_j^2 \right\}$$

$$\begin{aligned} \hat{\beta}^{\text{ridge}} = \underset{\beta}{\operatorname{argmin}} \sum_{i=1}^N \left(y_i - \sum_{j=1}^p x_{ij} \beta_j \right)^2, \\ \text{subject to } \sum_{j=1}^p \beta_j^2 \leq t, \end{aligned}$$

岭迹图

- 多重共线性
- 筛选k



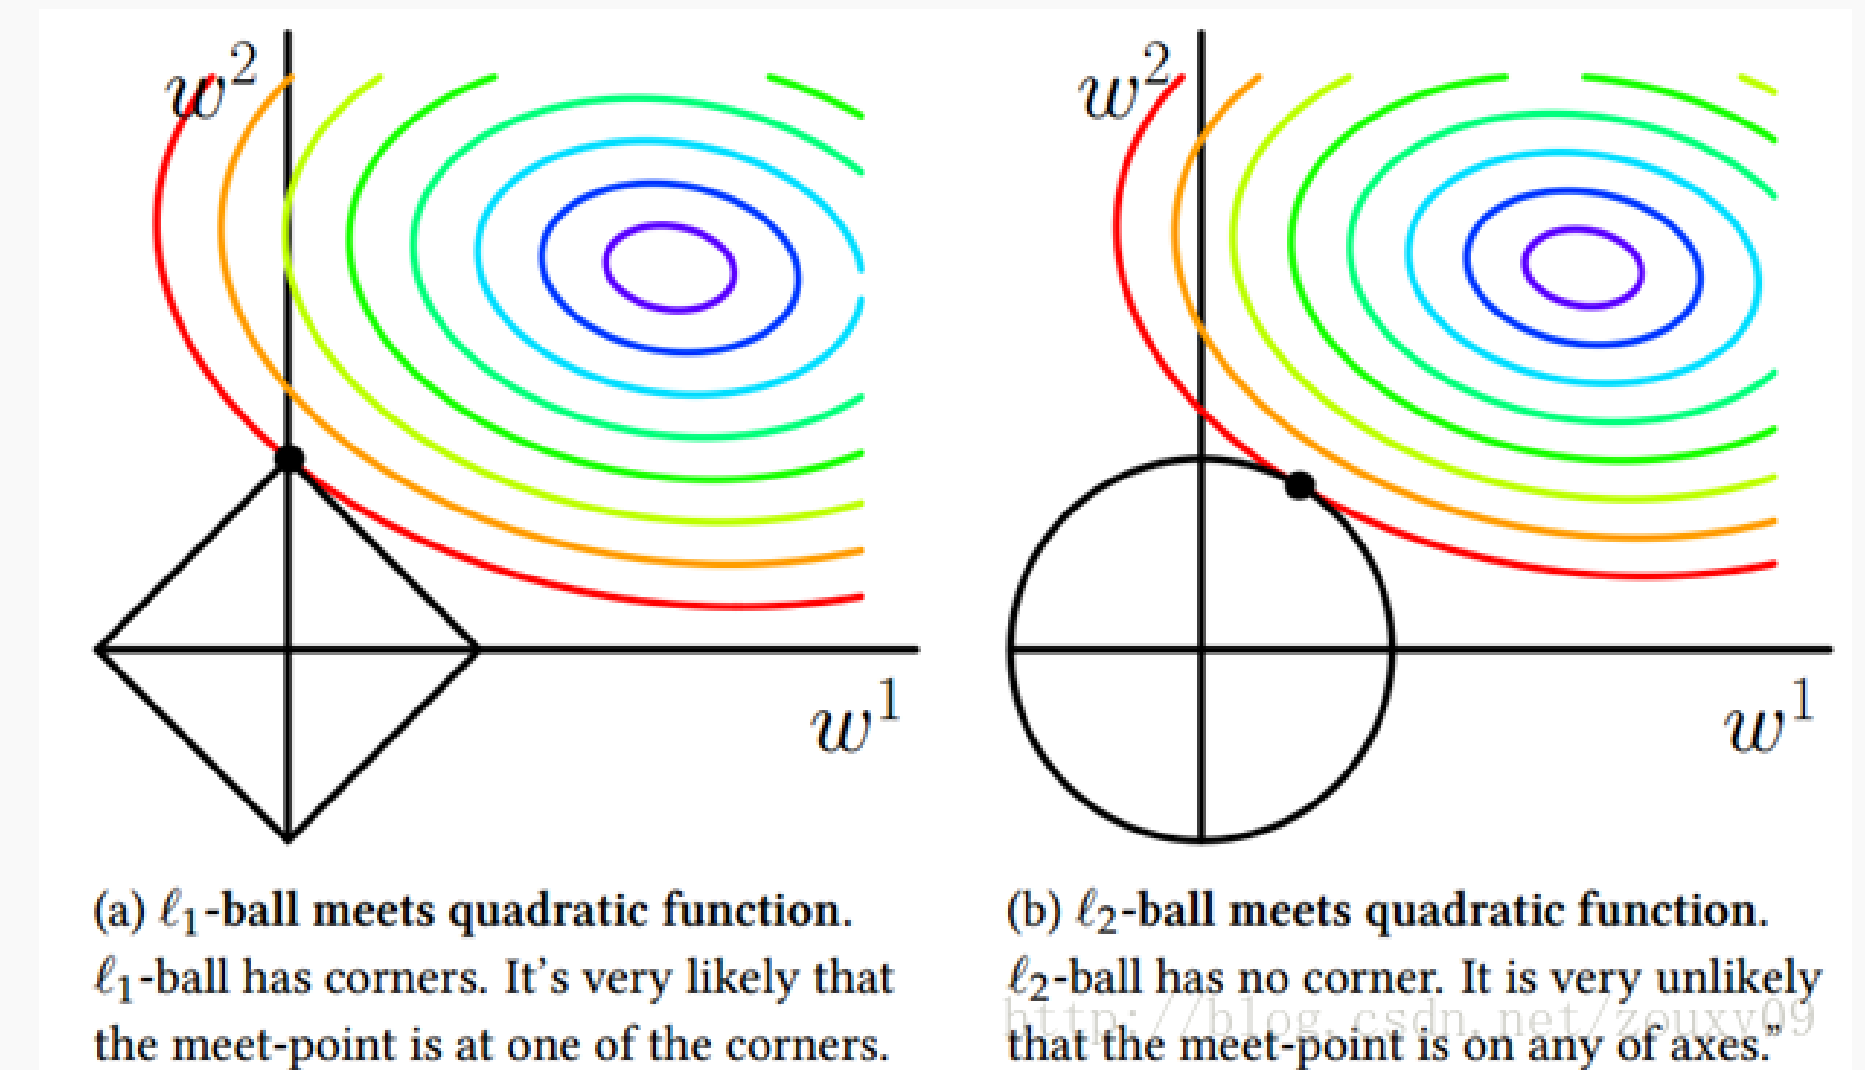
Lasso、弹性网

Lasso回归

- 岭回归的一般形式

$$\tilde{\beta} = \operatorname{argmin}_{\beta} \left\{ \sum_{i=1}^N (y_i - \sum_{j=1}^p x_{ij} \beta_j)^2 + \lambda \sum_{j=1}^p |\beta_j| \right\}$$

- 变量的系数为0，实现筛选变量



弹性网

综合和岭回归和Lasso

$$\operatorname{argmin}_{\beta} \left\{ \sum_{i=1}^N (y_i - \sum_{j=1}^p x_{ij} \beta_j)^2 + \mathbf{k} \sum_{j=1}^p (\alpha \beta_j^2 + (1 - \alpha) |\beta_j|) \right\}$$